

Optimización de portafolios de inversión en criptomonedas mediante algoritmos bioinspirados

Gordillo Solis Ivan Javier

Índice

1. Introducción

La optimización de portafolios de inversión constituye una tarea fundamental dentro del ámbito financiero, ya que busca asignar de manera eficiente los recursos disponibles entre distintos activos, con el objetivo de maximizar el rendimiento esperado y minimizar el riesgo asociado.

En el contexto del mercado de criptomonedas, este problema adquiere una complejidad adicional debido a su alta volatilidad, sensibilidad a eventos externos y cambios abruptos en las tendencias de precios. Estas características dificultan la predicción del comportamiento del mercado y limitan la efectividad de los métodos tradicionales de optimización.

Ante este panorama, los algoritmos bioinspirados —estrategias de búsqueda basadas en procesos naturales— se presentan como una alternativa viable para abordar problemas no lineales y de alta dimensionalidad, caracterizados por un gran número de variables y restricciones.

Si bien estas metaheurísticas no garantizan alcanzar el óptimo global, han demostrado ser altamente efectivas en la obtención de soluciones aproximadas de buena calidad en problemas complejos.

En este trabajo se propone el uso de algoritmos bioinspirados para la optimización de portafolios de criptomonedas, con el objetivo de analizar su capacidad para equilibrar la relación riesgo-rendimiento en un entorno altamente dinámico.

2. Criptomonedas

Las criptomonedas son un sistema digital de intercambio descentralizado (*peer to peer*) en el que la criptografía se utiliza para generar y transferir valor. Al ser descentralizadas, no existe una autoridad única que las regule; por ello, en cada transacción se requiere un mecanismo de verificación.

- Verificar que el monto sea correcto.
- Verificar que el remitente tenga fondos suficientes.
- Evitar el doble gasto de una misma unidad monetaria.

Este proceso de aseguramiento y verificación forma parte de lo que se conoce como minería.

2.1. Tipos de criptomonedas

El conjunto de criptomonedas más valiosas cambia con el tiempo. En la Tabla ?? se presentan algunas de las más representativas.

Debido a su relevancia histórica y de mercado, Bitcoin se utiliza en este documento como referencia para explicar de manera general el fundamento, la creación y el mantenimiento de las criptomonedas.

Cuadro 1: Comparativa de criptomonedas principales

Bitcoin	Ethereum	Ripple	Litecoin
Primera criptomonedas digital (2009); registra transacciones en la cadena de bloques.	Lanzada en 2015, permite contratos inteligentes y aplicaciones descentralizadas.	Red de liquidación global en tiempo real para pagos internacionales de bajo costo.	Basada en código abierto, con mayor tasa de generación de bloques que Bitcoin.

2.2. Blockchain

La *blockchain* de Bitcoin es, en esencia, un registro público que almacena todas las transacciones realizadas, además de la creación de nuevas unidades. La cadena se construye enlazando cada bloque nuevo con referencias criptográficas a bloques anteriores.

Los componentes principales de un bloque son:

- Un hash de referencia al bloque previo.
- El hash propio del bloque.
- Fecha de creación.
- Información de transacciones incluidas.

2.3. Cómo se sustenta el sistema

Para entender el mecanismo de Bitcoin, es necesario describir el rol del minero. Un minero recolecta transacciones, valida su legitimidad (monto correcto, fondos suficientes y ausencia de duplicados) y las agrupa como candidatas a bloque.

Cualquier persona puede participar como minero con el software y una copia actualizada de la cadena de bloques. En la práctica, la minería se ha vuelto altamente competitiva por la demanda computacional, lo que implica hardware especializado y alto consumo energético.

Para que un bloque sea aceptado, deben cumplirse condiciones básicas:

- Todas las transacciones deben ser válidas.
- El hash del bloque debe cumplir la condición de dificultad.

Esa condición se obtiene al aplicar la función hash doble SHA-256 al bloque candidato. No basta cualquier resultado; el valor debe cumplir un criterio específico de rareza:

- Estar por debajo de un umbral objetivo.
- Presentar múltiples ceros iniciales en su representación.

Cuando un minero encuentra un hash válido, el bloque se agrega a la cadena y el resto de la red puede verificarlo. Como incentivo, se otorga una recompensa en Bitcoin y comisiones de transacción. Además, la emisión de nuevos bitcoins disminuye de forma programada hasta un máximo de 21 millones de monedas.

2.4. Volatilidad del mercado

La volatilidad de las criptomonedas, en particular de Bitcoin, suele relacionarse con la ausencia de un valor fundamental único que funcione como ancla de precio. En consecuencia, los movimientos se ven influenciados por el sentimiento del mercado, la especulación y las narrativas mediáticas, lo cual favorece episodios de burbuja y efecto rebaño entre inversionistas.

Para dimensionar esta volatilidad, es útil compararla con mercados tradicionales. La volatilidad anualizada de Bitcoin ha oscilado históricamente entre 60 % y 100 %, mientras que índices bursátiles como el S&P 500 presentan volatilidades típicas de 15 % a 20 %. Esta diferencia implica que las fluctuaciones diarias en criptomonedas pueden ser de 5 % a 10 %, movimientos que en mercados tradicionales se considerarían eventos extremos.

Las causas de esta alta volatilidad incluyen:

- **Mercado relativamente pequeño:** menor liquidez comparada con mercados tradicionales, lo que amplifica el impacto de transacciones grandes.
- **Operación continua:** el mercado opera 24/7, sin pausas que permitan asimilar información.
- **Sensibilidad a noticias:** anuncios regulatorios, adopción institucional o eventos de seguridad generan reacciones inmediatas.
- **Comportamiento especulativo:** predominio de inversionistas que buscan ganancias a corto plazo.

Esta volatilidad extrema tiene implicaciones directas para la optimización de portafolios. Los métodos tradicionales, que asumen distribuciones normales de rendimientos, subestiman la frecuencia de eventos extremos en criptomonedas. Por ello, se requieren enfoques que consideren las colas pesadas de la distribución y que puedan adaptarse a cambios abruptos en las condiciones del mercado.

3. Optimización de portafolios

El manejo de portafolios se refiere al proceso de identificar, seleccionar y administrar un conjunto de inversiones. Esto incluye la asignación de recursos, el seguimiento del desempeño y la actualización del portafolio en el tiempo.

El problema de optimización de portafolios se formalizó con el trabajo de Harry Markowitz (1952), base de la Teoría Moderna del Portafolio.

“La optimización de portafolios puede definirse como el uso de métodos matemáticos para seleccionar activos considerando preferencias de decisión, restricciones relevantes e incertidumbre.”

Este problema puede formularse de distintas maneras:

- I. Minimizar el riesgo para un rendimiento objetivo.

- II. Maximizar el rendimiento esperado para un nivel de riesgo dado.
- III. Balancear riesgo y rendimiento con un factor de aversión al riesgo.
- IV. Minimizar el riesgo sin imponer meta de rendimiento.
- V. Maximizar el rendimiento sin imponer límite de riesgo.

3.1. Definiciones

3.1.1. Rendimiento del activo

Es la tasa de ganancia o pérdida de un activo en un periodo de tiempo. Una pérdida se representa con un valor negativo.

El rendimiento del activo i en el periodo t puede definirse como:

$$r_{i,t} = \frac{p_{i,t} - p_{i,t-1} + d_{i,t}}{p_{i,t-1}} \quad (1)$$

donde:

- $p_{i,t}$ es el precio de cierre del activo i en el periodo t
- $p_{i,t-1}$ es el precio de cierre en el periodo anterior
- $d_{i,t}$ representa los dividendos en el periodo t

El periodo de análisis puede ser diario, semanal, mensual o anual, dependiendo de la frecuencia de los datos utilizados.

3.1.2. Portafolio

Sea un portafolio compuesto por n activos, donde w_i representa la proporción de capital invertida en el activo i , cumpliendo la restricción de presupuesto:

$$\sum_{i=1}^n w_i = 1 \quad (2)$$

El rendimiento esperado del portafolio se define como:

$$\mu_p = \sum_{i=1}^n w_i \mu_i \quad (3)$$

donde μ_i es el rendimiento esperado del activo i .

En notación vectorial:

$$\mu_p = \mathbf{w}^\top \boldsymbol{\mu} \quad (4)$$

El riesgo del portafolio, medido mediante la varianza, se expresa como:

$$\sigma_p^2 = \mathbf{w}^\top \Sigma \mathbf{w} \quad (5)$$

donde Σ es la matriz de covarianzas entre los activos.

3.1.3. Modelo de media-varianza

El modelo clásico de Markowitz busca minimizar el riesgo del portafolio para un nivel de rendimiento esperado dado:

$$\min_{\mathbf{w}} \quad \mathbf{w}^\top \Sigma \mathbf{w} \quad (6)$$

$$\text{sujeto a} \quad \mathbf{w}^\top \boldsymbol{\mu} = \mu_0 \quad (7)$$

$$\sum_{i=1}^n w_i = 1 \quad (8)$$

$$w_i \geq 0, \quad i = 1, \dots, n \quad (9)$$

donde μ_0 es el rendimiento objetivo del portafolio.

Este modelo establece un compromiso entre riesgo y rendimiento, generando el conjunto de soluciones conocidas como portafolios eficientes.

3.1.4. Short selling

Es la venta de un activo que no se posee, con la expectativa de recomprarlo a menor precio. En términos de modelado, suele asociarse a pesos negativos. En el modelo clásico de Markowitz, esta práctica puede excluirse imponiendo $w_i \geq 0$.

3.1.5. Portafolio eficiente

Un portafolio factible es eficiente si maximiza el rendimiento esperado para un nivel de riesgo dado, o equivalentemente, minimiza el riesgo para un rendimiento esperado dado. En otras palabras, no existe otro portafolio que ofrezca mayor rendimiento sin incrementar el riesgo, ni uno que reduzca el riesgo sin sacrificar rendimiento.

Este concepto es central en la teoría de Markowitz: entre todos los portafolios posibles, solo un subconjunto cumple con esta condición de eficiencia, y son precisamente estos los que un inversionista racional debería considerar.

3.1.6. Frontera eficiente

La frontera eficiente es la curva que representa gráficamente el conjunto de portafolios eficientes en el espacio riesgo-rendimiento. Cada punto sobre esta curva corresponde a una combinación óptima de activos para un nivel de riesgo específico.

Geométricamente, la frontera tiene forma de hipérbola en el plano (σ_p, μ_p) . Los portafolios ubicados por debajo de la frontera son subóptimos, ya que existe al menos un portafolio eficiente que ofrece mayor rendimiento para el mismo nivel de riesgo. Los portafolios por encima de la frontera no son alcanzables con los activos disponibles.

El problema de optimización de portafolios consiste, en esencia, en encontrar puntos sobre esta frontera que satisfagan las preferencias del inversionista y las restricciones del problema.

3.2. Indicadores de riesgo

La medición del riesgo es fundamental para la optimización de portafolios. Existen diversas métricas, cada una con características que las hacen más o menos apropiadas según el contexto y los objetivos del inversionista.

3.2.1. Varianza y desviación estándar

La varianza mide la dispersión total de los rendimientos respecto a su media. Para un activo con rendimientos $r_1, r_2, \dots, r_T$ y media $\bar{r}$, se define como:

$$\sigma^2 = \frac{1}{T-1} \sum_{t=1}^T (r_t - \bar{r})^2 \quad (10)$$

La desviación estándar σ es la raíz cuadrada de la varianza y se interpreta como la volatilidad del activo. Es la medida de riesgo utilizada en el modelo clásico de Markowitz.

Una limitación de la varianza es que penaliza tanto las desviaciones positivas como las negativas, cuando en realidad solo las pérdidas representan riesgo para el inversionista.

3.2.2. Semivarianza

La semivarianza aborda la limitación anterior al considerar únicamente las desviaciones por debajo de un umbral τ (típicamente la media o cero):

$$SV = \frac{1}{T} \sum_{t=1}^T \min(r_t - \tau, 0)^2 \quad (11)$$

Esta métrica captura el riesgo de pérdida (*downside risk*) sin penalizar los rendimientos favorables. Su uso es apropiado cuando el inversionista tiene aversión asimétrica al riesgo.

3.2.3. Value at Risk (VaR)

El VaR representa la pérdida máxima esperada en un horizonte temporal dado, para un nivel de confianza α (comúnmente 95 % o 99 %). Formalmente, es el cuantil α de la distribución de pérdidas:

$$\text{VaR}_\alpha(L) = \inf\{l \in \mathbb{R} : P(L \leq l) \geq \alpha\} \quad (12)$$

Por ejemplo, un $\text{VaR}_{95\%}$ de \$10,000 indica que existe un 95 % de probabilidad de que las pérdidas no excedan dicha cantidad.

El VaR es ampliamente utilizado en la industria financiera por su interpretabilidad. Sin embargo, presenta limitaciones: no es una medida coherente de riesgo (no cumple la propiedad de subaditividad) y no proporciona información sobre la magnitud de las pérdidas cuando estas exceden el umbral.

3.2.4. Conditional Value at Risk (CVaR)

El CVaR, también conocido como Expected Shortfall, mide la pérdida promedio en los escenarios que exceden el VaR. Para un nivel de confianza α :

$$\text{CVaR}_\alpha(L) = \mathbb{E}[L \mid L \geq \text{VaR}_\alpha(L)] \quad (13)$$

donde L representa la pérdida del portafolio.

A diferencia del VaR, el CVaR es una medida coherente de riesgo y captura la severidad de las pérdidas extremas en la cola de la distribución. Esto lo hace particularmente adecuado para mercados con alta volatilidad, como el de criptomonedas, donde los eventos extremos son más frecuentes que en mercados tradicionales.

Además, el CVaR tiene propiedades matemáticas favorables: es convexo, lo que facilita su uso en problemas de optimización.

3.2.5. Comparativa de indicadores

Cuadro 2: Comparativa de indicadores de riesgo

Indicador	Ventajas	Limitaciones
Varianza	Simple de calcular; ampliamente conocida; convexa	Penaliza ganancias y pérdidas por igual
Semivarianza	Solo considera pérdidas; asimetría realista	Mayor complejidad computacional; menos datos disponibles
VaR	Interpretación intuitiva; estándar regulatorio	No es coherente; ignora magnitud de pérdidas extremas
CVaR	Coherente; captura colas; convexo	Requiere estimación de distribución; sensible a datos extremos

Para el contexto de criptomonedas, donde la distribución de rendimientos presenta colas pesadas y asimetría, el CVaR resulta especialmente apropiado al capturar el comportamiento en escenarios de pérdidas extremas.

3.3. Indicadores de desempeño

Además de las métricas de riesgo, existen indicadores que evalúan el desempeño de un portafolio considerando simultáneamente el rendimiento obtenido y el riesgo asumido.

3.3.1. Ratio de Sharpe

El ratio de Sharpe, propuesto por William Sharpe, mide el exceso de rendimiento por unidad de riesgo. Se define como:

$$S = \frac{\mu_p - r_f}{\sigma_p} \quad (14)$$

donde μ_p es el rendimiento esperado del portafolio, r_f es la tasa libre de riesgo y σ_p es la desviación estándar del portafolio.

Un ratio de Sharpe mayor indica un mejor desempeño ajustado por riesgo. Esta métrica permite comparar portafolios con diferentes niveles de riesgo en una escala común y es ampliamente utilizada en la industria para evaluar estrategias de inversión.

En el contexto de criptomonedas, donde no existe una tasa libre de riesgo claramente definida, es común utilizar $r_f = 0$ o una tasa de referencia del mercado tradicional.

3.3.2. Ratio de Sortino

El ratio de Sortino es una variante del Sharpe que utiliza la semivarianza en lugar de la desviación estándar, penalizando únicamente la volatilidad negativa:

$$S_o = \frac{\mu_p - r_f}{\sigma_d} \quad (15)$$

donde σ_d es la desviación estándar de los rendimientos negativos (downside deviation). Este indicador es más apropiado cuando la distribución de rendimientos es asimétrica.

3.4. Formas de representar un portafolio

En el contexto de algoritmos metaheurísticos, la forma en que se codifica una solución afecta directamente la eficiencia de la búsqueda. Para el problema de optimización de portafolios, la representación más directa es un vector de pesos $\mathbf{w} = (w_1, w_2, \dots, w_n)$, donde cada componente indica la proporción del capital asignada a cada activo.

Sin embargo, esta representación directa puede generar soluciones no factibles durante el proceso de búsqueda, particularmente cuando se violan restricciones como $\sum w_i = 1$ o los límites individuales de cada peso. Por ello, se han propuesto codificaciones alternativas:

- **Representación directa con reparación:** se utiliza el vector de pesos directamente, pero se aplica un mecanismo de normalización después de cada actualización para garantizar que se cumplan las restricciones. Por ejemplo, dividiendo cada peso entre la suma total: $w'_i = w_i / \sum_j w_j$.
- **Representación híbrida:** combina una parte binaria para la selección de activos (cuáles incluir en el portafolio) con una parte continua para la asignación de pesos. Es útil cuando se imponen restricciones de cardinalidad.
- **Codificación indirecta:** en lugar de representar pesos directamente, se codifican parámetros que luego se transforman en pesos válidos mediante una función de decodificación.

La elección de la representación depende de las restricciones del problema y del algoritmo utilizado. Para algoritmos basados en movimiento continuo, como PSO, la representación directa con reparación suele ser la más natural y eficiente.

3.5. Restricciones del mundo real

El modelo base de Markowitz impone la restricción de presupuesto $\sum w_i = 1$. En aplicaciones reales suelen añadirse restricciones adicionales.

3.5.1. Límites mínimos y máximos

Se imponen cotas inferiores y superiores para cada peso:

- **Límite inferior:** evita asignaciones demasiado pequeñas, que pueden incrementar costos de transacción.
- **Límite superior:** evita concentraciones excesivas y mejora la diversificación.

3.5.2. Cardinalidad

Controla cuántos activos pueden componer el portafolio:

- **Exacta:** exige exactamente K activos.
- **Suave:** fija un rango permitido de activos.

Con cardinalidad, el problema suele volverse no convexo y más difícil de resolver con métodos exactos; por ello se usan penalizaciones o procedimientos de poda de activos de bajo peso .

3.5.3. Rotación

Mide el cambio de pesos respecto a una asignación previa. Es relevante en estrategias de horizonte largo para evitar costos excesivos por comisiones e impuestos. Una forma común de modelarla es:

$$\sum_{i=1}^n |w_i^{(t)} - w_i^{(t-1)}| \leq \tau \quad (16)$$

donde τ es el límite máximo de rotación permitido.

4. Metaheurísticas y algoritmos bioinspirados

Las metaheurísticas son estrategias de alto nivel diseñadas para guiar procesos de búsqueda hacia soluciones de buena calidad en problemas de optimización complejos. A diferencia de los métodos exactos, que garantizan encontrar el óptimo global pero pueden requerir tiempos computacionales prohibitivos, las metaheurísticas buscan un equilibrio entre calidad de solución y eficiencia computacional.

El problema de optimización de portafolios, particularmente cuando se incorporan restricciones como cardinalidad o límites de rotación, se convierte en un problema NP-difícil que no puede resolverse eficientemente con métodos exactos. En estos casos, las metaheurísticas ofrecen una alternativa práctica para obtener soluciones aproximadas de alta calidad.

4.1. Clasificación de metaheurísticas

Las metaheurísticas pueden clasificarse según diversos criterios:

- **Basadas en trayectoria vs. poblacionales:** las primeras trabajan con una única solución que se modifica iterativamente (como búsqueda tabú o recocido simulado), mientras que las segundas mantienen un conjunto de soluciones que evolucionan en paralelo.
- **Inspiración natural:** muchas metaheurísticas se inspiran en procesos biológicos o físicos, como la evolución (algoritmos genéticos), el comportamiento colectivo de animales (inteligencia de enjambre) o el enfriamiento de metales (recocido simulado).

4.2. Algoritmos bioinspirados

Los algoritmos bioinspirados constituyen una familia de metaheurísticas que emulan mecanismos observados en la naturaleza. Su popularidad se debe a su capacidad para abordar problemas con espacios de búsqueda de alta dimensionalidad, funciones objetivo no diferenciables y restricciones complejas.

Entre las principales categorías se encuentran:

- **Algoritmos evolutivos:** inspirados en la teoría de la evolución de Darwin, utilizan operadores de selección, cruzamiento y mutación para evolucionar poblaciones de soluciones. Ejemplos: algoritmos genéticos, estrategias evolutivas, programación genética.
- **Inteligencia de enjambre:** modelan el comportamiento colectivo de grupos de organismos que, mediante interacciones simples entre individuos, exhiben comportamientos emergentes complejos. Ejemplos: optimización por enjambre de partículas (PSO), optimización por colonia de hormigas (ACO), algoritmo de abejas.

4.3. Inteligencia de enjambre

La inteligencia de enjambre se refiere a la capacidad de sistemas compuestos por agentes simples para resolver problemas complejos mediante cooperación descentralizada. Cada agente sigue reglas locales sencillas, pero la interacción colectiva produce un comportamiento global inteligente.

Características distintivas de estos algoritmos:

- **Autoorganización:** el comportamiento global emerge sin control centralizado.
- **Comunicación indirecta:** los agentes comparten información a través del entorno o mediante señales simples.
- **Robustez:** el sistema tolera la pérdida de agentes individuales sin colapsar.
- **Flexibilidad:** capacidad de adaptarse a cambios en el entorno.

Ejemplos naturales incluyen el comportamiento de parvadas de aves, cardúmenes de peces, colonias de hormigas y enjambres de abejas. Estos fenómenos han inspirado algoritmos de optimización que aprovechan la inteligencia colectiva para explorar eficientemente espacios de búsqueda complejos.

5. Optimización por enjambre de partículas (PSO)

La optimización por enjambre de partículas (PSO, por sus siglas en inglés), propuesta por Kennedy y Eberhart, es una metaheurística inspirada en el comportamiento colectivo observado en sistemas naturales, como parvadas de aves o cardúmenes de peces.

El algoritmo emplea un conjunto de agentes denominados partículas, donde cada partícula representa una solución candidata dentro del espacio de búsqueda. Estas partículas se desplazan ajustando su posición con base en su experiencia individual y en la mejor experiencia encontrada por el grupo.

En cada iteración, las partículas actualizan su velocidad y posición con el objetivo de acercarse a regiones prometedoras de la función objetivo. Este proceso continúa hasta alcanzar un número máximo de iteraciones o hasta que la mejora entre iteraciones sea marginal.

Este mecanismo de cooperación permite balancear la exploración del espacio de búsqueda con la explotación de las mejores soluciones encontradas.

5.1. Modelo matemático

El comportamiento de cada partícula se define mediante dos ecuaciones principales: la actualización de la velocidad y la actualización de la posición.

$$v_i(t+1) = v_i(t) + c_1 r_1 (p_{best,i} - x_i(t)) + c_2 r_2 (g_{best} - x_i(t)) \quad (17)$$

$$x_i(t+1) = x_i(t) + v_i(t+1) \quad (18)$$

donde:

- $x_i(t)$ representa la posición de la partícula i en la iteración t
- $v_i(t)$ es la velocidad de la partícula
- $p_{best,i}$ es la mejor posición encontrada por la partícula
- g_{best} es la mejor posición global del enjambre
- c_1 y c_2 son coeficientes de aceleración
- $r_1, r_2 \sim U(0, 1)$ son valores aleatorios

5.2. Componentes del algoritmo

Cada partícula dentro del enjambre posee los siguientes elementos:

- Posición: representa una solución candidata en el espacio de búsqueda.
- Velocidad: determina la dirección y magnitud del movimiento.
- Memoria individual (p_{best}): mejor solución encontrada por la partícula.
- Memoria global (g_{best}): mejor solución encontrada por el enjambre.

El algoritmo opera de forma iterativa, evaluando la calidad de cada partícula mediante una función objetivo y actualizando sus parámetros en consecuencia.

5.3. Estructura del algoritmo

El Algoritmo ?? presenta el pseudocódigo de PSO. El proceso inicia con la generación aleatoria de posiciones y velocidades, seguido de un ciclo iterativo donde cada partícula actualiza su estado basándose en su experiencia y la del enjambre.

Algoritmo 1: PSO(pob, c_1, c_2)

Entrada: pob : tamaño del cúmulo de partículas
 c_1 : importancia del mejor valor personal
 c_2 : importancia del mejor valor global
Salida: g_best : mejor posición dentro del cúmulo

```
1  $P \leftarrow \text{inicializar\_población}(pob);$ 
2 para  $i \leftarrow 1$  hasta  $MAX\_ITER$  hacer
3   para cada  $partícula\ p_i \in P$  hacer
4      $calidad \leftarrow f(p_i);$                                 // evalúa la función objetivo
5     si  $calidad > f(p\_best_i)$  entonces
6        $p\_best_i \leftarrow p_i;$ 
7     fin
8   fin
9    $g\_best \leftarrow \text{mejor } p\_best \in P;$ 
10  para cada  $partícula\ p_i \in P$  hacer
11     $v_i \leftarrow v_i + c_1 * U(0, 1) * (p\_best - p_i) + c_2 * U(0, 1) * (g\_best - p_i);$ 
12     $p_i \leftarrow p_i + v_i;$ 
13  fin
14 fin
15 regresar  $g\_best;$ 
```

5.4. Topologías de comunicación

Las topologías de comunicación definen cómo las partículas comparten información dentro del enjambre, lo cual influye directamente en el balance entre exploración y explotación del algoritmo.

La elección de la topología afecta dos aspectos fundamentales: la velocidad de convergencia y la capacidad de escapar de óptimos locales. Topologías con mayor conectividad aceleran la convergencia pero pueden provocar convergencia prematura; topologías más restringidas mantienen diversidad a costa de iteraciones adicionales.

5.4.1. Modelo global (*gbest*)

En esta topología, todas las partículas tienen acceso a la mejor solución encontrada por cualquier miembro del enjambre. La ecuación de velocidad utiliza g_{best} como atractor social:

$$v_i(t+1) = wv_i(t) + c_1r_1(p_{best,i} - x_i(t)) + c_2r_2(g_{best} - x_i(t)) \quad (19)$$

Esta es la topología original propuesta por Kennedy y Eberhart. Su principal ventaja es la convergencia rápida, ya que todas las partículas se dirigen hacia la mejor región conocida. Sin embargo, en problemas multimodales (con múltiples óptimos locales), el enjambre puede quedar atrapado prematuramente en un óptimo local.

5.4.2. Modelo local (*lbest*)

Cada partícula solo se comunica con un subconjunto de vecinos, típicamente definido por un anillo donde cada partícula conoce a sus k vecinos más cercanos en el índice del enjambre. En lugar de g_{best} , se utiliza $l_{best,i}$, la mejor posición entre los vecinos de la partícula i :

$$v_i(t+1) = wv_i(t) + c_1r_1(p_{best,i} - x_i(t)) + c_2r_2(l_{best,i} - x_i(t)) \quad (20)$$

Esta topología preserva mayor diversidad en el enjambre y reduce el riesgo de convergencia prematura. La información sobre buenas regiones se propaga gradualmente, permitiendo que diferentes partes del enjambre exploren distintas áreas del espacio de búsqueda.

5.4.3. Consideraciones para la selección

Para problemas con paisajes de aptitud suaves y un solo óptimo global, la topología global suele ser preferible por su eficiencia. En problemas multimodales o con alta dimensionalidad, como la optimización de portafolios con restricciones, la topología local puede ofrecer mejores resultados al mantener la diversidad del enjambre.

Cuadro 3: Comparativa de topologías de comunicación en PSO

Aspecto	Global (gbest)	Local (lbest)
Convergencia	Rápida	Más lenta, gradual
Riesgo de óptimos locales	Alto (convergencia prematura)	Bajo (mayor exploración)
Diversidad del enjambre	Se reduce rápidamente	Se mantiene por más tiempo
Problemas recomendados	Unimodales, convexos	Multimodales, alta dimensionalidad
Complejidad de implementación	Simple	Requiere definir vecindario

5.5. Modelos de velocidad

El modelo de velocidad determina la dinámica del movimiento de las partículas y el balance entre exploración (búsqueda global) y explotación (refinamiento local). La formulación original de PSO presentaba problemas de convergencia, lo que motivó el desarrollo de variantes más estables.

5.5.1. Factor de inercia

Shi y Eberhart introdujeron el factor de inercia w para controlar la influencia de la velocidad previa:

$$v_i(t+1) = wv_i(t) + c_1r_1(p_{best,i} - x_i(t)) + c_2r_2(g_{best} - x_i(t)) \quad (21)$$

El parámetro w regula el balance exploración-explotación:

- $w > 1$: la partícula tiende a expandir su trayectoria (mayor exploración, posible divergencia).
- $w \approx 1$: comportamiento similar al PSO original.
- $0 < w < 1$: la partícula desacelera gradualmente (mayor explotación).

Una estrategia común es decrementar w linealmente durante la ejecución, comenzando con valores altos (≈ 0.9) para explorar y terminando con valores bajos (≈ 0.4) para refinar las soluciones.

5.5.2. Factor de constricción

Clerc y Kennedy propusieron el factor de constricción χ como alternativa para garantizar convergencia. Se deriva analíticamente de las condiciones de estabilidad del sistema:

$$v_i(t+1) = \chi [v_i(t) + c_1r_1(p_{best,i} - x_i(t)) + c_2r_2(g_{best} - x_i(t))] \quad (22)$$

donde:

$$\chi = \frac{2}{\left|2 - \phi - \sqrt{\phi^2 - 4\phi}\right|}, \quad \phi = c_1 + c_2, \quad \phi > 4 \quad (23)$$

Con valores típicos $c_1 = c_2 = 2.05$ (lo que da $\phi = 4.1$), se obtiene $\chi \approx 0.7298$. Esta formulación elimina la necesidad de limitar la velocidad máxima y proporciona convergencia garantizada.

5.5.3. PSO Barebones

Kennedy propuso esta variante simplificada que elimina completamente el concepto de velocidad. La nueva posición se muestrea de una distribución gaussiana centrada entre la mejor posición personal y la global:

$$x_i(t+1) \sim \mathcal{N}\left(\frac{p_{best,i} + g_{best}}{2}, |p_{best,i} - g_{best}|\right) \quad (24)$$

La media de la distribución es el punto medio entre $p_{best,i}$ y g_{best} , mientras que la desviación estándar es la distancia entre ambos. Esta formulación reduce el número de parámetros a ajustar y puede ser efectiva en problemas donde el ajuste de parámetros tradicionales resulta complejo.

5.5.4. Comparativa de modelos

Cuadro 4: Comparativa de modelos de velocidad en PSO

Modelo	Ventajas	Desventajas	Parámetros
PSO Original	Simple de implementar	Puede diverger; requiere límites de velocidad	c_1, c_2, v_{max}
Factor de inercia	Control explícito exploración/explotación	Sensible al valor de w ; requiere ajuste	w, c_1, c_2
Constricción	Convergencia garantizada; sin v_{max}	Menos flexible que inercia	χ, c_1, c_2
Barebones	Pocos parámetros; evita ajuste fino	Puede ser muy aleatorio; menos control	Ninguno

6. Metodología (Propuesta PSO)

6.1. Datos del mercado

Los datos utilizados en este trabajo corresponden a precios históricos de criptomonedas, los cuales fueron obtenidos mediante la biblioteca `yfinance` de Python, que permite acceder a información financiera desde fuentes públicas.

Se seleccionaron las siguientes criptomonedas:

- Bitcoin (BTC)
- Ethereum (ETH)
- Solana (SOL)
- Cardano (ADA)

Debido a su relevancia dentro del mercado y disponibilidad de datos históricos.

El periodo de análisis abarca desde 2020 hasta 2024, utilizando una frecuencia diaria, lo que permite capturar el comportamiento del mercado y su volatilidad en el tiempo.

A partir de estos datos, se calcularon los rendimientos logarítmicos de cada activo, los cuales son utilizados como base para la construcción y evaluación de los portafolios.

$$r_t = \ln \left(\frac{P_t}{P_{t-1}} \right) \quad (25)$$

Donde P_t representa el precio del activo en el tiempo t .

El motivo de utilizar rendimientos logarítmicos radica en su capacidad para manejar mejor las variaciones porcentuales y su propiedad de aditividad, lo que facilita el análisis de los portafolios y la comparación entre diferentes activos.

6.2. Como se maneja la volatilidad

6.2.1. Funcion objetivo

6.2.2. Modelo CGARCH

6.3. Parametros del algoritmo

7. Resultados

8. Analisis de resultados

9. Conclusiones